Black Box: včasné varovanie študentov pred študijným preťažením*

Kyryl Tkachenko, Tymofii Trembovetskyi, Alex Vyšný
Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií
xtkachenko@stuba.sk xtrembovetskyi@stuba.sk xvysny@stuba.sk

30. október 2026

Abstrakt

Vysokoškolskí študenti dostávajú termíny zadaní, testov a skúšok z viacerých zdrojov a že sa v niektorom týždni nahromadí priveľa povinností, často zistia až vtedy, keď je neskoro. Dlhodobé preťaženie pritom patrí medzi hlavné príčiny stresu a vyhorenia študentov. V článku prinášame prehľad poznatkov o študijnej záťaži a jej vnímaní, o nástrojoch na sledovanie pohody a o systémoch včasného varovania vo vzdelávaní aj mimo neho. Ukazujeme, že existujúce riešenia buď termíny iba zobrazujú, alebo sledujú pohodu bez väzby na konkrétne povinnosti, a že takmer všetky ukladajú citlivé údaje mimo zariadenia používateľa. Na tomto základe navrhujeme lokálnu aplikáciu Black Box, ktorá z odhadov časovej náročnosti termínov počíta týždennú záťaž, 7 až 14 dní vopred varuje pred preťaženým týždňom a po náročnom období zobrazí časovú os termínov, záťaže a zaznamenaných pocitov. Opisujeme model výpočtu záťaže inšpirovaný sledovaním tréningovej záťaže športovcov, architektúru typu local-first a plán overenia s merateľnými ukazovateľmi.

1 Úvod

Študent v priebehu semestra pracuje naraz na piatich až siedmich predmetoch. Termíny odovzdania zadaní sú v informačnom systéme školy, zmeny termínov testov prichádzajú e-mailom a dohody o tímových stretnutiach vznikajú v skupinových chatoch. Každý zdroj samostatne vyzerá zvládnuteľne. Problém nastáva, keď sa termíny z rôznych predmetov zbehnú do toho istého týždňa: študent si to uvedomí až pár dní vopred, keď už nemá priestor prácu rozložiť.

Že takéto obdobia nie sú náhodné, ale opakujú sa v predvídateľnom rytme semestra, ukázal projekt StudentLife [22]. Autori počas desiatich týždňov sledovali 48 študentov pomocou senzorov smartfónu a krátkych dotazníkov a zistili, že stres stúpa a spánok aj fyzická aktivita klesajú práve v obdobiach so zvýšeným počtom termínov. Táto štúdia bola prvotným podnetom pre našu tému.

*Semestrálny projekt v predmete Metódy inžinierskej práce, ak. rok 2026/27, vedenie: Ing. Ivan Kapustík

Ak sa záťaž dá v dátach spätne rozpoznať, dá sa ju aj vopred predpovedať, a to z údajov, ktoré študent pozná: z termínov a z odhadu, koľko práce si vyžiadajú.

Aplikáciu, ktorú navrhujeme, sme nazvali Black Box podľa letovej zapisovacej jednotky. Tá turbulencii nezabráni, ale zaznamená, čo sa stalo, aby sa z toho dalo poučiť. Naša aplikácia ide o krok ďalej: okrem záznamu sa snaží na turbulenciu upozorniť skôr, než nastane.

Článok je usporiadaný takto. V časti 2 zhŕňame poznatky o strese, vyhorení a vnímaní študijnej záťaže. Časť 3 prehľadne porovnáva existujúce prístupy: kalendáre, nástroje na sledovanie pohody, systémy včasného varovania vo vzdelávaní a analogické riešenie zo športovej vedy. V časti 4 opisujeme návrh aplikácie Black Box vrátane modelu výpočtu záťaže a architektúry. Časť 5 predstavuje plán overenia a merateľné ukazovatele. Otvorené otázky rozoberáme v časti 6 a záverečné poznámky prináša časť 7.

2 Preťaženie študentov a jeho príčiny

2.1 Stres a vyhorenie

Vyhorenie je podľa Maslachovej a Leitera dlhodobá reakcia na chronické pracovné stresory, ktorá má tri zložky: vyčerpanie, cynizmus (odstup od práce) a pocit neúčinnosti [14]. Schaufeli a kol. ukázali, že tento koncept sa dá preniesť aj na štúdium: štúdium je pre študenta prácou so zadanými úlohami a termínmi a vyhorenie študentov sa dá spoľahlivo merať v rôznych krajinách [17]. Pre náš projekt je dôležité najmä to, že vyhorenie nevzniká naraz, ale hromadí sa z opakovaných období preťaženia.

Rozsah problému dokladajú aj veľké prieskumy. Medzinárodný projekt Svetovej zdravotníckej organizácie zistil, že približne 35 % študentov prvého ročníka malo počas života a 31 % za posledných 12 mesiacov príznaky aspoň jednej z bežných duševných porúch [2]. Prehľad Pascoeovej a kol. zhŕňa, že akademický stres, najmä tlak termínov a skúšok, znižuje študijný výkon, motiváciu a zvyšuje riziko predčasného ukončenia štúdia [16].

2.2 Vnímaná a skutočná záťaž

Kember upozorňuje, že pocit preťaženia nezodpovedá jednoducho počtu hodín, ktoré študent strávi učením [11]. Vnímanie záťaže závisí aj od toho, ako je organizovaná výučba a hodnotenie, ako náročné je učivo pochopiť a aká je motivácia študenta. Z toho pre nás vyplývajú dva dôsledky. Po prvé, nestačí sledovať celkový počet hodín za semester, ale jeho rozloženie v čase. Po druhé, objektívny odhad záťaže treba dopĺňať subjektívnym údajom o tom, ako sa študent cíti.

2.3 Prečo študenti preťaženie nepredvídajú

Aj keby mal študent všetky termíny pred očami, predpoveď záťaže mu sťažujú dva dobre zdokumentované javy. Prvým je *plánovací klam*: ľudia systematicky podceňujú, koľko času im úloha zaberie, a to aj vtedy, keď vedia, že podobné úlohy v minulosti trvali dlhšie [5]. Druhým je *prokrastinácia*: metaanalýza Steela ukazuje, že úsilie sa s blížiacim sa termínom prudko zvyšuje a že odkladanie

je medzi študentmi mimoriadne rozšírené [20]. Výsledkom je, že práca na viacerých termínoch sa v skutočnosti sústredí do niekoľkých dní pred nimi a prekryv termínov sa prejaví silnejšie, než by naznačoval rovnomerný plán.

Oba javy priamo ovplyvňujú návrh nášho modelu. Odhad hodín od používateľa nemôžeme brať doslova, ale musíme ho kalibrovať podľa toho, ako sa jeho odhady v minulosti zhodovali so skutočnosťou. Prácu na termíne nemáme rozkladať rovnomerne, ale s väčšou váhou na dni tesne pred ním.

3 Existujúce prístupy

3.1 Kalendáre a plánovače úloh

Bežné kalendáre a zoznamy úloh dokážu zhromaždiť termíny z viacerých zdrojov, najmä vďaka štandardu iCalendar [6], ktorý podporuje aj väčšina univerzitných informačných systémov. Termín je však v nich iba bod v čase. Kalendár nevie, že za odovzdaním projektu je dvadsať hodín práce a za priebežným testom päť, a preto nedokáže povedať, ktorý týždeň bude ťažký. Taký úsudok zostáva na študentovi, ktorý ho podľa časti 2 robí systematicky zle.

3.2 Sledovanie pohody a osobná informatika

Na opačnej strane sú nástroje, ktoré sledujú, ako sa človek cíti. Metodicky vychádzajú z *ekologického momentového hodnotenia* (EMA), pri ktorom respondent opakovane hodnotí svoj stav v prirodzenom prostredí, namiesto toho, aby si ho neskôr spätne vybavoval [18]. Takýto záznam je presnejší ako dotazník na konci obdobia, pretože ho neskresľuje pamäť. StudentLife [22] kombinoval krátke EMA dotazníky s pasívnymi senzormi a ukázal, že zmeny pohody súvisia s priebehom semestra. Išlo však o výskumný nástroj: údaje sa odosielali na server a vyhodnocovali ich výskumníci, nie samotní študenti.

Li, Dey a Forlizzi opísali systémy *osobnej informatiky* piatimi etapami: príprava, zber, integrácia, reflexia a akcia [13]. Podľa ich zistení používatelia najčastejšie zlyhávajú pri integrácii údajov z rôznych zdrojov a pri reflexii, teda pri hľadaní súvislostí. Väčšina aplikácií na sledovanie nálady končí pri zbere: ukáže graf nálady, ale nepovie, čím bol spôsobený, lebo o termínoch nič nevie.

3.3 Systémy včasného varovania vo vzdelávaní

V oblasti učiacej sa analytiky vznikli systémy, ktoré varujú pred neúspechom v predmete. Známym príkladom je Course Signals na Purdueovej univerzite, ktorý zo známok a aktivity v systéme na riadenie výučby priraďoval študentom semafor rizika [1]. Tieto systémy sú inštitucionálne: údaje spracúva škola, varovanie sa týka jedného predmetu a cieľom je študijný výsledok, nie celková záťaž študenta naprieč predmetmi.

3.4 Analógia zo športu: sledovanie tréningovej záťaže

Najbližšie k nášmu problému má prístup, ktorý sa používa v športovej vede. Tréneri sledujú záťaž športovca a porovnávajú záťaž posledného týždňa s priemerom predchádzajúcich štyroch týždňov. Gabbett ukázal, že riziko zranenia nestúpa ani tak s celkovým objemom tréningu, ako s jeho prudkým nárastom

oproti tomu, na čo je športovec zvyknutý [8]. Tento *pomer akútnej a chronickej záťaže* (ACWR) je jednoduchý a zrozumiteľný, čo je pre aplikáciu určenú bežnému používateľovi výhoda.

Impellizzeri a kol. však upozorňujú na jeho metodické slabiny: pomer je nestabilný pri malej chronickej záťaži, napríklad na začiatku obdobia, a jeho prahové hodnoty sa nedajú preberať bez overenia v konkrétnom kontexte [10]. Z analógie preto preberáme myšlienku porovnávať záťaž s individuálnym zvykom, ale nie konkrétne prahy. Tie musíme overiť na študentoch.

3.5 Súkromie údajov o pohode

Údaje o tom, ako sa človek cíti, môžu súvisieť s jeho zdravím. Všeobecné nariadenie o ochrane údajov ich v takom prípade radí medzi osobitné kategórie osobných údajov s prísnejšou ochranou [7] a v Slovenskej republike ho dopĺňa zákon č. 18/2018 Z. z. [15]. Prax aplikácií pre duševné zdravie je pritom nepriaznivá. Huckvale a kol. zistili, že 33 z 36 skúmaných aplikácií pre depresiu a odvykanie od fajčenia odosielalo údaje tretím stranám, najmä reklamným a analytickým službám, a len časť z nich to uviedla v zásadách ochrany súkromia [9].

Alternatívou je prístup *local-first*, ktorý Kleppmann a kol. charakterizujú siedmimi ideálmi; medzi nimi sú práca bez pripojenia, dlhodobá dostupnosť údajov a to, že používateľ má nad svojimi údajmi plnú kontrolu [12]. Pri osobných údajoch o pohode je najbezpečnejším riešením, keď sa zo zariadenia vôbec nedostanú.

3.6 Zhrnutie

Tabuľka 1 porovnáva jednotlivé skupiny prístupov podľa piatich vlastností, ktoré považujeme pre náš problém za podstatné. Žiadny z nich nespája termíny, predpoveď záťaže a záznam pohody v nástroji, ktorý by mal študent pod vlastnou kontrolou.

Tabuľka 1: Porovnanie existujúcich prístupov (• áno, ○ čiastočne, – nie).

Prístup	Termíny	Predpoveď	Pohoda	Reflexia	Lokálne
Kalendáre, plánovače	•	–	–	–	○
Aplikácie na sledovanie nálady	–	–	•	○	○
StudentLife [22]	○	–	•	○	–
Course Signals [1]	–	○	–	–	–
Black Box (návrh)	•	•	•	•	•

4 Návrh riešenia Black Box

Black Box je desktopová aplikácia s tromi hlavnými funkciami: zhromaždenie termínov, predpoveď týždennej záťaže s varovaním a spätný pohľad na náročné obdobie. Používateľ pridá predmety a termíny ručne alebo importom súboru vo formáte iCalendar [6]. Ku každému termínu zadá odhad, koľko hodín práce mu zaberie, a typ termínu (zadanie, test, skúška), podľa ktorého aplikácia predvolí dĺžku prípravy.

4.1 Model týždennej záťaže

Pre termín i označme d_i jeho dátum, h_i odhad hodín a w_i počet dní prípravy. Odhad hodín najprv vynásobíme kalibračným koeficientom α (pozri ďalej) a rozložíme ho do dní pred termínom tak, aby váha rástla s blížiacim sa termínom, ako to zodpovedá poznatkom o prokrastinácii [20]. Záťaž dňa t je

$$L(t) = \alpha \sum_{i} h_i \, k_i(d_i - t), \qquad k_i(x) = \frac{2\,(w_i - x)}{w_i\,(w_i + 1)} \quad \text{pre } x = 0, \dots, w_i - 1, \tag{1}$$

pričom mimo tohto rozsahu je $k_i(x) = 0$. Jadro k_i je lineárne klesajúce so vzdialenosťou od termínu a jeho súčet je 1, takže celkový počet hodín sa zachová. Záťaž týždňa T je súčtom dennej záťaže $Z(T) = \sum_{t \in T} L(t)$.

Varovanie pred týždňom T aplikácia vydá, ak je splnená aspoň jedna z dvoch podmienok:

$$Z(T) > c \qquad \text{alebo} \qquad \frac{Z(T)}{\max\!\left(\frac{1}{4}\sum_{j=1}^{4} Z(T-j),\; c/2\right)} > \rho. \tag{2}$$

Prvá podmienka porovnáva záťaž s kapacitou c, teda počtom hodín týždenne, ktoré má študent popri výučbe na samostatnú prácu k dispozícii; zadáva ju sám. Druhá je obdoba pomeru akútnej a chronickej záťaže [8] a zachytí prudký nárast oproti predchádzajúcim štyrom týždňom. Dolná hranica $c/2$ v menovateli rieši nestabilitu pomeru na začiatku semestra, na ktorú upozorňujú Impellizzeri a kol. [10]. Počiatočné hodnoty $c = 20$ h a $\rho = 1{,}5$ sú pracovné a ich nastavenie je jedným z cieľov overenia. Model sa vyhodnocuje denne pre týždne, ktoré začínajú o 7 až 14 dní neskôr, aby mal študent na úpravu plánu aspoň týždeň.

Kalibrácia odhadov. Po uplynutí termínu sa aplikácia voliteľne opýta, koľko hodín práca skutočne trvala (s_i). Kalibračný koeficient je medián pomerov s_i/h_i za posledných najviac desať termínov; kým ich používateľ nemá aspoň päť, platí $\alpha = 1$. Medián sme zvolili namiesto priemeru, aby jeden extrémny termín nezmenil predpoveď na celý semester. Kalibrácia priamo reaguje na plánovací klam [5]: ak študent systematicky podceňuje, aplikácia jeho odhady zväčší.

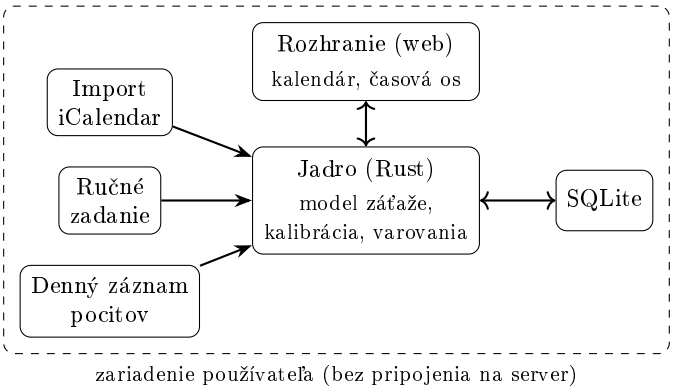
4.2 Denný záznam a spätný pohľad

Raz denne môže používateľ jedným kliknutím zaznamenať, ako sa cíti, na stupnici od 1 do 5. Krátky a opakovaný záznam vychádza z metódy EMA [18]; zámerne obmedzujeme jeho rozsah, aby ho používateľ po pár týždňoch neprestal vypĺňať. Raz týždenne sa aplikácia navyše opýta, či bol uplynulý týždeň preťažený. Táto odpoveď slúži ako referenčný údaj pri overovaní presnosti varovaní (časť 5).

Spätný pohľad zobrazí na spoločnej časovej osi tri vrstvy: termíny, vypočítanú záťaž $Z(T)$ a zaznamenané pocity. Podľa modelu osobnej informatiky [13] tým aplikácia preberá etapy integrácie a reflexie, ktoré pri samostatných nástrojoch zostávajú na používateľovi. Študent vidí, ktoré termíny sa na náročnom týždni podieľali najviac, a môže si nabudúce prácu na nich rozložiť skôr.

4.3 Architektúra

Aplikácia vzniká v nástroji Tauri [21], ktorý spája jadro v jazyku Rust s webovým používateľským rozhraním a v porovnaní s nástrojmi založenými na celom prehliadači vytvára výrazne menšie inštalačné balíky. Údaje sú uložené v lokálnej databáze SQLite [19], ktorá je jedným súborom v zariadení používateľa. Rozdelenie zodpovedností ukazuje obr. 1.



Obr. 1: Architektúra aplikácie Black Box. Všetky údaje zostávajú v zariadení používateľa.

Aplikácia nemá žiadnu serverovú časť a na svoju činnosť nepotrebuje internet. Nadväzuje tým na ideály local-first [12] a zohľadňuje zistenia o úniku údajov z aplikácií pre duševné zdravie [9]. Používateľ môže svoje údaje kedykoľvek exportovať do otvoreného formátu alebo ich úplne vymazať, čím aplikácia napĺňa právo na prenosnosť a vymazanie údajov podľa GDPR [7]. Synchronizácia medzi viacerými zariadeniami nie je v prvej verzii súčasťou návrhu.

5 Plán overenia

Aby sme vedeli posúdiť, či aplikácia skutočne pomáha, stanovili sme merateľné ukazovatele pre každú z troch funkcií.

Presnosť varovaní. Aplikáciu bude počas ôsmich týždňov semestra používať skupina najmenej 30 študentov. Za *skutočne preťažený* považujeme týždeň, ktorý študent v týždennej otázke označí ako preťažený alebo ktorého priemerný denný záznam je najviac 2. Varovania porovnáme s týmto referenčným údajom a vypočítame presnosť (podiel oprávnených varovaní) a úplnosť (podiel zachytených preťažených týždňov). Cieľom je presnosť aspoň 70 % a úplnosť aspoň 60 % pri predstihu najmenej 7 dní. Ako východiskový model použijeme jednoduché počítanie termínov v týždni; náš model by ho mal prekonať v ukazovateli F1.

Prínos kalibrácie. Pri termínoch, ku ktorým študenti zadajú skutočný počet hodín, porovnáme strednú absolútnu chybu odhadu pred kalibráciou a po nej. Očakávame, že kalibrácia chybu zníži, čo by potvrdilo vplyv plánovacieho klamu [5] aj v našom kontexte.

Použiteľnosť. Na konci overenia vyplnia účastníci dotazník SUS [4]. Cieľom je priemerné skóre aspoň 71, ktoré podľa Bangora a kol. zodpovedá slovnému hodnoteniu použiteľnosti ako dobrej [3]. Doplnkovým ukazovateľom je podiel dní, v ktorých študent vyplnil denný záznam; ak klesne pod 50 %, denný záznam je potrebné zjednodušiť.

Technické požiadavky. Aplikácia musí správne načítať aspoň 95 % udalostí z exportu univerzitného informačného systému vo formáte iCalendar a počas celého overenia nesmie odoslať žiadne údaje mimo zariadenia, čo overíme sledovaním sieťovej komunikácie.

6 Diskusia a otvorené otázky

Návrh má niekoľko obmedzení, ktoré chceme počas projektu preskúmať. Prvým je závislosť od odhadov používateľa. Kalibrácia síce koriguje systematickú chybu, ale nepomôže, ak študent odhady nezadáva vôbec. Zvažujeme preto predvolené odhady podľa typu termínu, ktoré by sa postupne prispôsobovali.

Druhým obmedzením je meranie pohody jedným číslom. Je to vedomý kompromis medzi presnosťou a ochotou záznam vypĺňať: validované dotazníky vyhorenia ako MBI-SS [17] majú 15 položiek a na denné použitie sa nehodia. Zostáva otvorené, či jednopoložkový záznam dostatočne zachytí zmeny, ktoré nás zaujímajú.

Tretím je prenositeľnosť prahov. Ako ukazuje kritika ACWR [10], prah, ktorý funguje v jednej skupine, nemusí fungovať v inej. Je možné, že hodnoty c a ρ sa budú musieť prispôsobovať jednotlivcovi, podobne ako kalibračný koeficient α.

Napokon, lokálne uloženie údajov vylučuje akékoľvek spoločné vyhodnocovanie. Na účely overenia preto účastníci exportujú anonymizovaný súhrn ukazovateľov sami a s ich výslovným súhlasom.

7 Záver

V článku sme zhrnuli poznatky o študijnom preťažení a o tom, prečo ho študenti sami nepredvídajú. Ukázali sme, že dostupné nástroje riešia vždy len časť problému: kalendáre poznajú termíny, ale nie záťaž, aplikácie na sledovanie pohody poznajú pocity, ale nie ich príčiny, a systémy včasného varovania vo vzdelávaní sú inštitucionálne a zamerané na známky.

Naším príspevkom je návrh aplikácie Black Box, ktorá tieto časti spája lokálne v zariadení študenta, a model výpočtu týždennej záťaže, ktorý preberá myšlienku pomeru akútnej a chronickej záťaže zo športovej vedy a dopĺňa ju o kalibráciu odhadov. Stanovili sme merateľné ukazovatele, podľa ktorých posúdime, či aplikácia svoj cieľ spĺňa.

Otvorené zostáva najmä to, či sa prahy varovania dajú nastaviť všeobecne a či jednoduchý denný záznam stačí na zachytenie preťaženia. Na tieto otázky odpovie overenie so skupinou študentov, ktoré je ďalším krokom projektu.

Literatúra

[1] Kimberly E. Arnold and Matthew D. Pistilli. Course signals at Purdue: Using learning analytics to increase student success. In *Proceedings of the 2nd International Conference on Learning Analytics and Knowledge (LAK '12)*, pages 267–270, Vancouver, Canada, 2012. ACM.

[2] Randy P. Auerbach et al. WHO world mental health surveys international college student project: Prevalence and distribution of mental disorders. *Journal of Abnormal Psychology*, 127(7):623–638, 2018.

[3] Aaron Bangor, Philip Kortum, and James Miller. Determining what individual SUS scores mean: Adding an adjective rating scale. *Journal of Usability Studies*, 4(3):114–123, 2009.

[4] John Brooke. SUS: A "quick and dirty" usability scale. In Patrick W. Jordan, Bruce Thomas, Bernard A. Weerdmeester, and Ian L. McClelland, editors, *Usability Evaluation in Industry*, pages 189–194. Taylor & Francis, London, 1996.

[5] Roger Buehler, Dale Griffin, and Michael Ross. Exploring the "planning fallacy": Why people underestimate their task completion times. *Journal of Personality and Social Psychology*, 67(3):366–381, 1994.

[6] Bernard Desruisseaux. Internet calendaring and scheduling core object specification (iCalendar). RFC 5545, Internet Engineering Task Force, September 2009. `https://datatracker.ietf.org/doc/html/rfc5545`.

[7] Európsky parlament a Rada Európskej únie. Nariadenie (EÚ) 2016/679 o ochrane fyzických osôb pri spracúvaní osobných údajov a o voľnom pohybe takýchto údajov (všeobecné nariadenie o ochrane údajov). Úradný vestník Európskej únie, L 119, s. 1–88, `https://eur-lex.europa.eu/legal-content/SK/TXT/?uri=CELEX:32016R0679`, 2016. [cit. 2026-10-30].

[8] Tim J. Gabbett. The training–injury prevention paradox: Should athletes be training smarter and harder? *British Journal of Sports Medicine*, 50(5):273–280, 2016.

[9] Kit Huckvale, John Torous, and Mark E. Larsen. Assessment of the data sharing and privacy practices of smartphone apps for depression and smoking cessation. *JAMA Network Open*, 2(4):e192542, 2019.

[10] Franco M. Impellizzeri, Mark R. Tenan, Tom Kempton, Andrew Novak, and Aaron J. Coutts. Acute:chronic workload ratio: Conceptual issues and fundamental pitfalls. *International Journal of Sports Physiology and Performance*, 15(6):907–913, 2020.

[11] David Kember. Interpreting student workload and the factors which shape students' perceptions of their workload. *Studies in Higher Education*, 29(2):165–184, 2004.

[12] Martin Kleppmann, Adam Wiggins, Peter van Hardenberg, and Mark McGranaghan. Local-first software: You own your data, in spite of the

cloud. In *Proceedings of the 2019 ACM SIGPLAN International Symposium on New Ideas, New Paradigms, and Reflections on Programming and Software (Onward! 2019)*, pages 154–178, Athens, Greece, 2019. ACM.

[13] Ian Li, Anind Dey, and Jodi Forlizzi. A stage-based model of personal informatics systems. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (CHI '10)*, pages 557–566, Atlanta, USA, 2010. ACM.

[14] Christina Maslach and Michael P. Leiter. Understanding the burnout experience: Recent research and its implications for psychiatry. *World Psychiatry*, 15(2):103–111, 2016.

[15] Národná rada Slovenskej republiky. Zákon č. 18/2018 Z. z. o ochrane osobných údajov a o zmene a doplnení niektorých zákonov. `https://www.slov-lex.sk/ezbierky/pravne-predpisy/SK/ZZ/2018/18/`, 2018. [cit. 2026-10-30].

[16] Michaela C. Pascoe, Sarah E. Hetrick, and Alexandra G. Parker. The impact of stress on students in secondary school and higher education. *International Journal of Adolescence and Youth*, 25(1):104–112, 2020.

[17] Wilmar B. Schaufeli, Isabel M. Martínez, Alexandra Marques Pinto, Marisa Salanova, and Arnold B. Bakker. Burnout and engagement in university students: A cross-national study. *Journal of Cross-Cultural Psychology*, 33(5):464–481, 2002.

[18] Saul Shiffman, Arthur A. Stone, and Michael R. Hufford. Ecological momentary assessment. *Annual Review of Clinical Psychology*, 4:1–32, 2008.

[19] SQLite Consortium. SQLite documentation. `https://www.sqlite.org/docs.html`, 2026. [cit. 2026-10-30].

[20] Piers Steel. The nature of procrastination: A meta-analytic and theoretical review of quintessential self-regulatory failure. *Psychological Bulletin*, 133(1):65–94, 2007.

[21] Tauri Contributors. Tauri: Build smaller, faster, and more secure desktop and mobile applications. `https://tauri.app/`, 2026. [cit. 2026-10-30].

[22] Rui Wang, Fanglin Chen, Zhenyu Chen, Tianxing Li, Gabriella Harari, Stefanie Tignor, Xia Zhou, Dror Ben-Zeev, and Andrew T. Campbell. StudentLife: Assessing mental health, academic performance and behavioral trends of college students using smartphones. In *Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp '14)*, pages 3–14, Seattle, USA, September 2014. ACM.